Федеральное государственное автономное образовательное учреждение

высшего образования

«Национальный исследовательский университет «Высшая школа экономики»

ИНДИВИДУАЛЬНОЕ ЗАДАНИЕ и ПЛАН-ГРАФИК

в структурном подразделении факультета компьютерных наук,

студенту 1 курса очной формы обучения

Гузенко Артёму Александровичу

образовательной программы	Прикладная математика и информатика
уровня	бакалавриат
по направлению	01.03.02 Прикладная математика и информатика
факультета	компьютерных наук
Вид практики	учебная
Тип практики	учебная
Срок прохождения практики	с 01 июля 2026 по 14 июля 2026
Руководитель практики от	Евгений Анатольевич Паточенко
ФКН НИУ ВШЭ	Старший преподаватель департамента больших данных и информационного поиска

Цель прохождения практики:	Получение и закрепление практических навыков по разработке систем, использующих технологию Retrieval-Augmented Generation (RAG), на примере построения системы вопросно-ответного взаимодействия с текстом годового отчёта компании X5 за 2025 год.

Задачи практики:

1. изучить базовые принципы построения RAG-систем и их основные компоненты (парсинг документов, разбиение на фрагменты, эмбеддинги, векторное хранилище, генеративная модель, промпт-инжиниринг);
2. реализовать базовое (baseline) решение RAG-пайплайна для ответа на вопросы по годовому отчёту компании X5;
3. разработать систему метрик для объективной оценки качества ответов (полнота извлечения контекста, отсутствие галлюцинаций, фактическая корректность, точность извлечения числовых значений);
4. провести серию экспериментов по улучшению отдельных компонентов системы: способов парсинга PDF, методов разбиения текста, эмбеддинг-моделей, векторных хранилищ, генеративных LLM, промптов и методов ранжирования;
5. на основании результатов экспериментов собрать и обосновать итоговую конфигурацию RAG-системы;
6. оценить итоговое решение на наборе вопросов и проанализировать полученные результаты.

Содержание практики (вопросы, подлежащие изучению):	1. Архитектура и принципы работы систем Retrieval-Augmented Generation (RAG); 2. Методы извлечения текста из PDF-документов (PyMuPDF) и предобработки данных; 3. Стратегии разбиения текста на чанки: рекурсивное и семантическое разбиение, подбор параметров; 4. Модели мультиязычных и русскоязычных эмбеддингов, сравнительный анализ BGE-M3, e5-small и e5-large; 5. Организация векторного хранилища и методов поиска: InMemory, FAISS, гибридный поиск Dense+BM25 с Reciprocal Rank Fusion; 6. Генеративные языковые модели: Qwen, Vikhr, Saiga; их сравнение и выбор оптимальной для задачи; 7. Разработка и тестирование системных промптов для повышения точности и безопасности ответов; 8. Дополнительные улучшения RAG: кросс-энкодерный реранкинг, перефразирование запроса, фильтрация небезопасных запросов; 9. Метрики оценки качества вопросно-ответных систем: RAGAS (ContextRecall, Faithfulness, FactualCorrectness), авторские метрики (number_match, source_recall), LLM-as-a-Judge; 10. Практические аспекты работы с ограниченными GPU-ресурсами: квантование моделей, управление памятью, кэширование экспериментов.

Планируемые результаты:

Сроки проведения	Планируемые работы
01.07.2026	Инструктаж по ознакомлению с требованиями охраны труда, техники безопасности, пожарной безопасности, а также правилами внутреннего трудового распорядка
02.07.2026	Изучение материалов курса по архитектуре RAG-систем; постановка задачи и анализ требований
03.07.2026 – 04.07.2026	Подключение зависимостей, загрузка данных, реализация базовых функций пайплайна, создание базовой версии класса метрик
05.07.2026 – 06.07.2026	Реализация baseline-решения RAG; первичный запуск и проверка работоспособности, оценка работы базовой модели
07.07.2026 – 08.07.2026	Добавление новых метрик оценки качества (RAGAS, собственные метрики, LLM-судья)
09.07.2026	Реализация кеширования результатов экспериментов; подготовка тестового датасета
10.07.2026	Эксперименты: парсинг PDF, разбиение на фрагменты, анализ показателей метрик и поиск проблем в реализации и разметке данных
11.07.2026	Эксперименты: эмбеддинг-модели, векторные хранилища, анализ работы различных методов
12.07.2026	Эксперименты: генеративные LLM, системные промпты, подключение LLM с различными архитектурами, оптимизация памяти на GPU
13.07.2026	Эксперименты: методы ранжирования; сборка итоговой конфигурации системы
14.07.2026	Финальное тестирование, оформление ноутбука и подготовка отчёта по практике

Задание принято к исполнению 01.07.2026 г.

Студент  Гузенко А.А.

(подпись) *(фамилия, инициалы)*

УТВЕРЖДАЮ

Руководитель практики от ФКН НИУ ВШЭ:

Старший преподаватель департамента больших данных и информационного поиска		Е.А. Паточенко
Должность, место работы	*(подпись)*	*И.О.Фамилия*

Дата