Правительство Российской Федерации
Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет «Высшая школа экономики»

Факультет компьютерных наук
Образовательная программа бакалавриата 01.03.02 «Прикладная математика и информатика»

ОТЧЕТ
по учебной практике в структурном подразделении факультета компьютерных наук

Выполнил студент
группы БПМИ253
А.А. Гузенко



Проверил:

Руководитель практики от факультета компьютерных наук

Паточенко Евгений Анатольевич
(ФИО руководителя практики от ФКН)

Старший преподаватель департамента больших данных и информационного поиска
(должность руководителя практики от ФКН)

Дата _____ _____ _____
(оценка) (подпись)

Москва – 2026

Аннотация

Место проведения практики: структурное подразделение факультета компьютерных наук НИУ ВШЭ (курс «Разработка ИИ-агентов»), дистанционный формат с использованием облачной вычислительной платформы Kaggle.

Практика была посвящена разработке и последовательному улучшению системы вопросно-ответного взаимодействия с документами на основе подхода Retrieval-Augmented Generation (RAG). В качестве прикладной задачи использовался годовой отчёт компании X5 — на его основе была построена система, способная отвечать на фактологические вопросы о финансовых показателях компании с опорой на текст документа.

В ходе практики было реализовано базовое (baseline) решение и проведена серия из семи групп экспериментов: по способам парсинга PDF, методам разбиения текста на фрагменты (чанки), выбору эмбеддинг-моделей, векторным хранилищам, генеративным LLM, промпт-инжинирингу и способам ранжирования найденных фрагментов. По результатам экспериментов собрана и обоснована итоговая конфигурация системы, показавшая прирост по ключевым метрикам качества по сравнению с baseline-решением.

Содержание

Аннотация 2

Цель и задачи практики 4

Описание места прохождения практики 5
- Структура организации и подразделения 5
- Виды деятельности и основные задачи подразделения 5

Обзор изученных материалов, технологий и методов 6
- Подход Retrieval-Augmented Generation 6
- Используемые библиотеки и инструменты 6
- Изученные аналоги и альтернативные подходы 7

Описание методов, моделей и технологий для решения задачи 7
- Базовое (baseline) решение 7
- Система метрик оценки качества 7
- Эксперименты по улучшению компонентов системы 8
- Итоговая конфигурация RAG-системы 9

Описание полученных результатов 10

Заключение 12

Список использованных источников 13

Цель и задачи практики

Целью учебной практики являлось получение и закрепление практических навыков по разработке систем, использующих технологию Retrieval-Augmented Generation (RAG), на примере построения системы вопросно-ответного взаимодействия с текстом годового отчёта компании X5 за 2025 год.

Для достижения поставленной цели решались следующие задачи:

1. изучить базовые принципы построения RAG-систем и их основные компоненты (парсинг документов, разбиение на фрагменты, эмбеддинги, векторное хранилище, генеративная модель, промпт-инжиниринг);
2. реализовать базовое (baseline) решение RAG-пайплайна для ответа на вопросы по годовому отчёту компании X5;
3. разработать систему метрик для объективной оценки качества ответов (полнота извлечения контекста, отсутствие галлюцинаций, фактическая корректность, точность извлечения числовых значений);
4. провести серию экспериментов по улучшению отдельных компонентов системы: способов парсинга PDF, методов разбиения текста, эмбеддинг-моделей, векторных хранилищ, генеративных LLM, промптов и методов ранжирования;
5. на основании результатов экспериментов собрать и обосновать итоговую конфигурацию RAG-системы;
6. оценить итоговое решение на наборе вопросов и проанализировать полученные результаты.

Описание места прохождения практики

Структура организации и подразделения

Практика проходила в рамках учебного процесса факультета компьютерных наук НИУ ВШЭ, в рамках мини-курса «Разработка ИИ-агентов» образовательной программы «Прикладная математика и информатика». Работа выполнялась дистанционно, с использованием облачной вычислительной платформы Kaggle, предоставляющей бесплатный доступ к вычислительным ресурсам (2×GPU T4).

Виды деятельности и основные задачи подразделения

Основной вид деятельности в рамках практики — исследовательская и работа по созданию построению прикладной системы обработки запрос от пользователя. Основные задачи, решаемые в рамках проекта включают:

- разработку и тестирование пайплайнов обработки неструктурированных текстовых данных (PDF-документов);
- подбор и сравнительную оценку моделей машинного обучения (эмбеддинг-модели, генеративные LLM, кросс-энкодеры);
- проектирование и реализацию систем автоматизированной оценки качества (метрики RAGAS, LLM-as-a-judge, собственные метрики);
- работу с ограниченными вычислительными ресурсами и оптимизацию под них (квантование моделей, кеширование промежуточных результатов эксперимента).

Обзор изученных материалов, технологий и методов

В ходе подготовки к выполнению практического задания были изучены материалы курса по архитектуре RAG-систем [1], годовой отчёт компании X5 за 2025 год [2], использованный в качестве прикладного набора данных, а также сопутствующая документация используемых библиотек и инструментов. Ниже приведён обзор ключевых технологий и подходов, задействованных в проекте.

Подход Retrieval-Augmented Generation

RAG — архитектурный подход, объединяющий поиск релевантной информации (retrieval) во внешнем источнике знаний с последующей генерацией ответа языковой моделью (generation) на основе найденного контекста. Такой подход позволяет генеративной модели отвечать на вопросы по конкретному документу, не требуя дообучения модели на этих данных, что позволяет быстро менять исходные документы, не потеряв при этом в качестве; снижает риск «галлюцинаций» из-за присутствия необходимого контекста — генерации моделью недостоверных фактов.

Используемые библиотеки и инструменты

- PyMuPDF — библиотека для парсинга PDF-документов [5], применяется для извлечения текста и таблиц из годового отчёта;
- LangChain / langchain-community / langchain-experimental — фреймворк для построения RAG-пайплайнов [3], использован для разбиения текста на фрагменты (RecursiveCharacterTextSplitter, SemanticChunker) и организации цепочки обработки запроса;
- HuggingFace Transformers, sentence-transformers, langchain-huggingface — для загрузки и запуска эмбеддинг-моделей и генеративных LLM [6];
- библиотеки, специализированные базы данных и расширения для организации векторного хранилища, индексации и быстрого поиска по векторным представлениям текста (эмбеддингам);
- RAGAS — фреймворк для автоматизированной оценки качества RAG-систем (метрики Context Recall, Faithfulness, Factual Correctness) [4];
- langchain-google-genai — интеграция с моделью Gemini, использованной в качестве модели-судьи (LLM-as-a-judge) для оценки качества ответов;
- bitsandbytes — библиотека для квантования весов генеративной модели с целью снижения потребления видеопамяти;
- pandas, matplotlib, seaborn — для агрегации, визуализации и табличного отображения результатов экспериментов.

Изученные аналоги и альтернативные подходы

В рамках экспериментов были изучены и сопоставлены между собой альтернативные решения на каждом из этапов пайплайна: разные библиотеки парсинга PDF (с извлечением и без извлечения таблиц), разные стратегии разбиения текста (по символам и семантическое разбиение), разные эмбеддинг-модели (в том числе мультиязычные и специализированные на русском языке), разные типы векторных хранилищ (in-memory, FAISS), разные генеративные модели семейства Qwen и не только, а также разные варианты системных промптов и методов ранжирования найденных фрагментов (в том числе гибридный поиск и кросс-энкодерное переранжирование).

Описание методов, моделей и технологий для решения задачи

Базовое (baseline) решение

В качестве отправной точки был реализован минимально работающий RAG-пайплайн, состоящий из следующих этапов:

1. загрузка и парсинг PDF годового отчёта с помощью PyMuPDFLoader;
2. разбиение текста на фрагменты алгоритмом RecursiveCharacterTextSplitter (размер фрагмента 2000 символов, перекрытие 200 символов);
3. построение эмбеддингов фрагментов с помощью мультиязычной модели multilingual-e5-small;
4. индексация фрагментов в векторном хранилище (in-memory) и поиск по косинусному сходству;
5. генерация ответа моделью Qwen/Qwen2.5-3B-Instruct [7] с детерминированным декодированием (do_sample=False, max_new_tokens=256);
6. оценка качества ответов с помощью набора метрик RAGAS на подготовленном наборе тестовых вопросов с эталонными ответами.

Система метрик оценки качества

Для объективной оценки результатов экспериментов была спроектирована и реализована система метрик, охватывающая различные аспекты качества RAG-системы:

- RAGAS Context Recall — оценивает, найден ли в контексте фрагмент, содержащий информацию, необходимую для ответа;
- RAGAS Faithfulness — оценивает, не содержит ли сгенерированный ответ фактов, не подтверждённых контекстом (индикатор галлюцинаций);
- RAGAS Factual Correctness — оценивает смысловое соответствие ответа эталонному;
- number_match — собственная метрика, разработанная в рамках проекта, проверяющая совпадение числовых значений в ответе с ожидаемыми, заранее введёнными значениями, представленными в разных единицах измерения;

– source_recall — собственная метрика, оценивающая совпадение страниц документа, использованных моделью, с эталонными страницами-источниками;
– LLM-as-a-judge — оценка общего качества ответа с текстовым обоснованием, выполняемая внешней языковой моделью (Gemini, модель gemini-3.1-flash-lite);
– ручная проверка ответов на выборке вопросов.

Для устойчивости вычислений реализация метрик выполнена с обработкой исключений (try/except), чтобы сбой в отдельной метрике не прерывал вычисление остальных при длительных прогонах экспериментов. Также был разработан отдельный класс RAGMetrics, вызывающий подсчёт всех метрик, и функция кеширования результатов экспериментов (сохранение и загрузка в формате pickle), позволяющая не повторять затратные по времени и по числу обращений к внешним API эксперименты при повторных запусках ноутбука.

Эксперименты по улучшению компонентов системы

Экспериментальная часть работы была организована как последовательное сравнение альтернатив для каждого компонента пайплайна при фиксированных остальных компонентах, что позволяет оценить индивидуальный вклад каждого изменения в итоговое качество системы, а также гарантирует быстрое масштабирование экспериментов. Было проведено семь групп исследований:

1. Парсинг PDF — сравнение стандартного постраничного извлечения текста и извлечения с дополнительным распознаванием таблиц (с последующей вставкой таблиц в формате Markdown внутри текста фрагмента);
2. Разбиение на фрагменты (чанкинг) — сравнение символьного разбиения (RecursiveCharacterTextSplitter) на части разных размеров (1500, 2000, 2500 символов) и семантического разбиения (SemanticChunker), учитывающего смысловые границы текста;
3. Эмбеддинг-модели — сравнение мультиязычной модели e5-small и e5-large, а также специализированной на русском языке модели deepvk/USER-BGE-M3 и мультиязычной BAAI/bge-m3;
4. Векторные хранилища — сравнение in-memory хранилища и FAISS, а также гибридного поиска Dense+BM25;
5. Генеративные LLM — сравнение моделей семейства Qwen (Qwen2.5-3B-Instruct и Qwen3-4B-Instruct-2507) с использованием 4-битного квантования для компактного размещения модели на доступной видеопамяти; попытка выделить ресурсы для запуска полноценных моделей с 7B параметров и отличной от Qwen архитектурой (Vikhrmodels/Vikhr-7B-instruct_0.4, IlyaGusev/mistral_7b_lora);
6. Системные промпты — сравнение нескольких вариантов промптов, в том числе укороченного базового варианта и промпта с усиленной защитой от галлюцинаций и prompt injection (strict_no_imagination), добавление метрик безопасности и защиты от prompt injection;

7. Методы ранжирования найденных фрагментов — сравнение чисто семантического (dense) поиска, гибридного поиска (комбинация dense-поиска и BM25 через Reciprocal Rank Fusion) и последующего переранжирования кандидатов кросс-энкодерной моделью DiTy/cross-encoder-russian-msmarco.

Для каждого эксперимента фиксировались количественные метрики и делался вывод об эффективности и целесообразности изменения, а результаты сохранялись в кеш для последующего использования при сборке итоговой конфигурации.

Итоговая конфигурация RAG-системы

По результатам экспериментов была собрана итоговая конфигурация системы, включающая:

- семантическое разбиение текста на фрагменты (SemanticChunker);
- эмбеддинг-модель deepvk/USER-BGE-M3 [8], специализированную на русском языке;
- гибридный поиск (dense-поиск + BM25 с объединением через Reciprocal Rank Fusion) с помощью EnsembleRetriever библиотеки LangChain;
- переранжирование топ-20 кандидатов кросс-энкодером DiTy/cross-encoder-russian-msmarco [9] с отбором 4 наиболее релевантных фрагментов;
- генеративную модель Qwen/Qwen3-4B-Instruct-2507 [7] с 4-битным квантованием, детерминированным декодированием и ограничением в 256 генерируемых токенов;
- системный промпт strict_no_imagination, ориентированный на минимизацию галлюцинаций за счёт запрета на домысливание фактов и явного указания отвечать «Ответ не найден» при отсутствии информации в контексте.

Итоговая цепочка обработки запроса реализована в виде функции final_rag_invoke, обёрнутой в RunnableLambda библиотеки LangChain, что обеспечивает единый интерфейс invoke для проверки решения на скрытом пуле вопросов.

Описание полученных результатов

В результате выполнения практического задания получена работающая RAG-система для ответов на вопросы по годовому отчёту компании X5, качество которой превышает показатели baseline-решения по ключевым метрикам. Ниже приведены основные количественные результаты, полученные в ходе экспериментов (таблица ??); полные материалы экспериментов доступны в [10].

Таблица 1 – Пошаговое улучшение RAG-системы

Конфигурация	number_match	source_recall	Комментарий
Baseline (символьное разбиение, e5-small, in-memory, Qwen2.5-3B, простой промпт)	0.38	0.23	Стартовая точка сравнения
Добавлен гибридный поиск (Dense + BM25, RRF)	0.78	0.47	Рост в ~2 раза по обеим метрикам
Добавлен кросс-энкодерное переранжирование (rerank_20_to_4)	0.66	0.27	Дополнительный прирост точности без увеличения времени ответа
Замена эмбеддера на deepvk/USER-BGE-M3	0.72	0.18	Лучшая модель по числовому совпадению
Итоговая конфигурация (семантический чанкинг, USER-BGE-M3, гибридный поиск, реранкинг, Qwen3-4B, строгий промпт с повышенной защищённостью)	0.78*	0.36*	*На вопросах, где модель дала содержательный ответ. Компромисс: высокая достоверность ценой ≈30–40% отказов

Основные наблюдения по результатам экспериментов:

- наибольший прирост качества извлечения информации дало применение гибридного поиска (комбинация плотного векторного поиска и BM25): показатель number-match вырос примерно вдвое по сравнению с чисто семантическим поиском, поскольку BM25 компенсирует слабость эмбеддинг-модели при поиске точных числовых значений и ключевых слов, что критично для отчёта с большим количеством финансовых показателей;
- переранжирование кандидатов кросс-энкодером дало дополнительный прирост качества без заметного увеличения времени отклика системы за счёт компактности используемой модели;
- переход на модель Qwen3-4B вместо Qwen2.5-3B обеспечил более качественную генерацию ответов на русском языке при сопоставимых вычислительных затратах;
- использование строгого защитного промпта (strict_no_imagination) существенно повышает достоверность ответов и снижает риск галлюцинаций, но ценой этого

является отказ модели отвечать на часть вопросов (по оценке — порядка 30–40% случаев), если релевантный фрагмент был найден не с исчерпывающей точностью;

– метрика source_recall в ряде экспериментов оставалась относительно низкой даже у конфигураций с хорошими показателями number_match, что указывает на неполное соответствие используемых моделью источников эталонным страницам документа при в целом корректном числовом ответе — это направление было отмечено как требующее дальнейшего изучения.

Итоговая конфигурация системы охарактеризована как сбалансированное решение, ориентированное на приоритет достоверности ответа перед полнотой покрытия вопросов: система стремится не выдавать неподтверждённую информацию, даже если это означает отказ от ответа в неоднозначных случаях. Суммарное время ответа на один вопрос в итоговой конфигурации составляет порядка 3–4 секунд, что было признано приемлемым для демонстрационного использования.

Дополнительно система была протестирована на устойчивость к вопросам с попытками prompt injection — строгий системный промпт послужил дополнительным защитным механизмом, ограничивающим отклонение модели от заданного формата ответа.

Заключение

В ходе учебной практики была решена поставленная задача построения RAG-системы для ответов на вопросы по годовому отчёту компании: реализовано baseline-решение, разработана система метрик, проведена серия экспериментов по всем ключевым компонентам пайплайна (парсинг документов, разбиение на фрагменты, эмбеддинги, векторное хранилище, генеративная модель, промпт, метод ранжирования), и на основании полученных данных собрана и обоснована итоговая конфигурация системы.

Практика позволила закрепить на прикладной задаче навыки работы с современными библиотеками для построения пайплайнов, использующих LangChain, HuggingFace Transformers, RAGAS. Был получен опыт организации и документирования экспериментов в условиях ограниченных вычислительных облачных ресурсов, а также опыт проектирования систем автоматизированной оценки качества генеративных моделей.

Наиболее трудоёмким этапом работы стала оптимизация процесса вычислений в условиях ограничений облачной платформы (объём видеопамяти, лимиты обращений к внешним API для метрики LLM-as-a-judge) — данная проблема была решена за счёт разработки системы кеширования промежуточных результатов экспериментов и пересмотра состава используемых метрик. Также ценным опытом стало столкновение с ограничениями локального оборудования, что потребовало изучения инструментов запуска языковых моделей на CPU (Ollama) и, в итоге, перехода на облачные вычисления.

Направления дальнейшей работы: повышение метрики source_recall за счёт более точного сопоставления используемых моделью фрагментов и страниц-источников документа; расширение тестового набора вопросов; эксперименты с более крупными генеративными моделями при появлении доступа к дополнительным вычислительным ресурсам; изучение альтернативных методов снижения количества отказов модели при сохранении высокой достоверности ответов.

Опыт построения и оценки RAG-систем может быть использован при выполнении выпускной квалификационной работы, если её тема будет связана с системами вопросно-ответного взаимодействия, поиском по документам или прикладными задачами обработки естественного языка с использованием больших языковых моделей. ВКР может использовать наработки, полученные при выполнении данной практики, при этом возможен более подробный анализ тем работы и улучшения модели RAG.

Список использованных источников

Список литературы

[1] Материалы курса «Создание ИИ-агентов» [Электронный ресурс]. — Режим доступа: https://edu.hse.ru/course/view.php?id=280959/ (дата обращения: 24.07.2026).

[2] Годовой отчёт компании X5 за 2025 год [Электронный ресурс]. — Режим доступа: https://www.x5.ru/ru/investors/reports/ (дата обращения: 24.07.2026).

[3] LangChain Documentation [Электронный ресурс]. — Режим доступа: https://python.langchain.com/ (дата обращения: 24.07.2026).

[4] RAGAS Documentation [Электронный ресурс]. — Режим доступа: https://docs.ragas.io/ (дата обращения: 24.07.2026).

[5] PyMuPDF (fitz) Documentation [Электронный ресурс]. — Режим доступа: https://pymupdf.readthedocs.io/ (дата обращения: 24.07.2026).

[6] HuggingFace Transformers Documentation [Электронный ресурс]. — Режим доступа: https://huggingface.co/docs/transformers/ (дата обращения: 24.07.2026).

[7] Qwen2.5-3B-Instruct / Qwen3-4B-Instruct-2507 [Электронный ресурс]. — Режим доступа: https://huggingface.co/Qwen (дата обращения: 24.07.2026).

[8] deepvk/USER-BGE-M3 [Электронный ресурс]. — Режим доступа: https://huggingface.co/deepvk/USER-bge-m3 (дата обращения: 24.07.2026).

[9] DiTy/cross-encoder-russian-msmarco [Электронный ресурс]. — Режим доступа: https://huggingface.co/DiTy/cross-encoder-russian-msmarco (дата обращения: 24.07.2026).

[10] Материалы и результаты собственных экспериментов, скомпилированные в рамках практики [Электронный ресурс]. — Режим доступа: https://disk.360.yandex.ru/d/cXjMDQDOugTh4g (дата обращения: 24.07.2026).

Таблица 2 – План-график прохождения практики

Дата	Содержание работ	Отметка о выполнении
01.07.2026 – 02.07.2026	Изучение материалов курса по архитектуре RAG-систем; постановка задачи и анализ требований к проекту	Выполнено
03.07.2026 – 04.07.2026	Подключение зависимостей, загрузка данных, реализация базовых функций пайплайна, создание базовой версии класса метрик	Выполнено
05.07.2026 – 06.07.2026	Реализация baseline-решения RAG; первичный запуск и проверка работоспособности, оценка работы базовой модели	Выполнено
07.07.2026 – 08.07.2026	Добавление новых метрик оценки качества (RAGAS, собственные метрики, LLM-судья)	Выполнено
09.07.2026	Реализация кеширования результатов экспериментов; подготовка тестового датасета вопросов	Выполнено
10.07.2026	Эксперименты: парсинг PDF, разбиение на фрагменты, анализ показателей метрик и поиск проблем в реализации и разметке данных	Выполнено
11.07.2026	Эксперименты: эмбеддинг-модели, векторные хранилища, анализ работы различных методов	Выполнено
12.07.2026	Эксперименты: генеративные LLM, системные промпты, подключение LLM с различными архитектурами, оптимизация занимаемой памяти на GPU	Выполнено
13.07.2026	Эксперименты: методы ранжирования; сборка итоговой конфигурации системы	Выполнено
14.07.2026	Финальное тестирование, оформление ноутбука и подготовка отчёта по практике	Выполнено